## به نام خدا

# پروژه نهایی درس امنیت شبکههای کامپیوتری

## عنوان پروژه: تشخیص باتنتهای P2P با کشف وابستگی جریان در ترافیک فرمان و کنترل (C&C)

این پروژه نهایی برای دانشجویان تحصیلات تکمیلی در حوزه امنیت شبکه های کامپیوتری، بر اساس مقاله " Pongling P2P و Kiuli Shao و Hongling Jiang طراحی شده است. "botnets by discovering flow dependency in C&C traffic هدف این پروژه، پیاده سازی رویکردی برای شناسایی باتنتهای P2P با تمرکز بر روی ترافیک فرمان و کنترل (C&C) آنها است.

#### مقدمه

باتنتها به یکی از تهدیدات اصلی اینترنت تبدیل شدهاند. مهاجمان از باتنتها به عنوان زیرساخت برای انواع جرایم سایبری، از جمله حملات محرومسازی از سرویس توزیعشده (DDoS)، ارسال هرزنامه، کلاهبرداری کلیکی، فیشینگ و ثبت کلیدها، استفاده می کنند. با پیشرفت سرویسهای ابری، مهاجمان آینده ممکن است از این سرویسها برای ایجاد باتنت و راهاندازی حملات بهره ببرند.

باتنتها از ساختارهای متمرکز به ساختارهای توزیعشده (Peer-to-Peer یا Peer) تکامل یافتهاند. در یک باتنت PPP، برخلاف ساختارهای متمرکز ، هیچ نقطه مرکزی برای سرور C&C وجود ندارد. هر بات هم به عنوان کلاینت و هم به عنوان سرور عمل میکند. این ساختار باعث می شود که حتی در صورت آفلاین شدن برخی نودها، باتنت PPP به فعالیت خود ادامه دهد و در برابر تغییرات پویا مقاوم باشد. Nugache ، Storm و Waledac از جمله محبوب ترین باتنتهای PPP هستند.

اکثر باتهای P2P مدرن حملات خود را به صورت مخفیانه انجام میدهند و رویکردهای تشخیص مبتنی بر ترافیک مخرب باتها ناکار آمد هستند. تشخیص باتنتهای P2P با چالشهای متعددی روبروست:

- 1. ترافیک باتنتهای P2P به ترافیک شبکههای P2P قانونی شباهت دارد و در ترافیک عادی پنهان میشود.
- بسیاری از باتنتهای P2P مانند Nugache ، Nugache و Conficker از مکانیزمهای رمزنگاری استفاده
   میکنند که رویکردهای مبتنی بر محتوای بسته را بی اثر می سازد.

- 3. باتهای P2P فعالیتهای مخرب خود را به صورت مخفیانه انجام میدهند.
  - 4. در باتنتهای P2P سرور مرکزی وجود ندارد.
  - 5. باتها از طریق پورتهای تصادفی با یکدیگر ارتباط برقرار می کنند.

این پروژه بر اساس مقالهی "C traffic&Detecting P2P botnets by discovering flow dependency in C" ، یک رویکرد تشخیص باتنت P2P را پیشنهاد می کند که با تمرکز بر روی ویژگیهای ذاتی ارتباطات فرمان و کنترل (C&C) آنها، باتهای P2P را شناسایی می کند. این رویکرد نیازی به بررسی ترافیک مخرب یا اطلاعاتی از باتها که توسط سیستمهای خارجی (مانند Honeypot یا IDS) ارائه شده، ندارد. این روش باتهای P2P را با کشف وابستگی جریان در ترافیک C&C شناسایی می کند. پس از کشف این وابستگیها، رویکرد پیشنهادی با استفاده از تکنیک خوشهبندی، باتهای P2P را از میزبانهای عادی متمایز می کند.

## معماری و پیادهسازی رویکرد تشخیص

همانطور که در شکل 2 مقاله مشخص است ، این رویکرد از سه مؤلفه اصلی تشکیل شده است:

- Flow Capture .1
- Flow Dependency Extractor .2
  - Bots Detector .3

#### بخش اول) Flow Capture (درصد نمره

این مرحله وظیفه دریافت جریانهای کاندید را بر عهده دارد و شامل دو ماژول است:

#### • (درصد نمره) Flow Generation

برای تشخیص وابستگی جریانها، بستههای خام باید به جریان تبدیل شوند. یک جریان به عنوان دنبالهای از بستهها بین یک مبدأ و یک مقصد در یک اتصال تعریف می شود. جریانها بر اساس اطلاعات پنج تایی شامل آدرسهای IP، پورتها و پروتکل مبدأ و یک مقصد در یک اتصال تعریف می شود. جریانها بر اساس اطلاعات پنج تایی شامل آدرس IP، پورت ها و پروت میزبان ادرس IP و پورت میزبان او پورت میزبان خارج از شبکه نظارت داخل شبکه نظارت شده هستند، در حالی که remotePort و remotePort آدرس IP و پورت میزبان خارج از شبکه نظارت شده می باشند. جریانها دوطرفه هستند، به این معنی که آدرس IP پورت مبدأ و آدرس IP پورت مقصد قابل جابجایی هستند. زمان بین هر دو بسته متوالی در یک جریان باید کمتر از آستانه Timeout باشد.

از آنجایی که اکثر باتنتهای P2P از پروتکل UDP یا TCP برای ارتباط استفاده می کنند ، ما بر روی جریانهای UDP و FIN ,ACK ,FIN بستههای ACK ,SYN-ACK ,SYN نشاندهنده ی شروع جریان و TCP تمرکز می کنیم. برای TCP تمرکز می کنیم. برای TCP بستههای TCP بستههای بایان جریان هستند. فقط جریانهای TCP موفق با handshake کامل تحلیل می شوند. برای ACK بستههای با همان پنج تایی در یک جریان UDP تجمیع می شوند و زمان بین هر دو بسته متوالی باید کمتر از آستانه Timeout باشد.

برای کشف وابستگی جریانها، از هدرهای بستههای TCP/UDP و اطلاعات زمانی استفاده می شود. این اطلاعات به راحتی قابل دسترسی هستند و مستقل از محتوای بسته می باشند.

#### اطلاعات جریان به صورت زیر ثبت می شود:

- 1. پنجتایی (five-tuple)
- 2. زمان شروع (start time): زمان رسیدن اولین بسته در یک جریان
- 3. زمان پایان (end time): زمان رسیدن آخرین بسته در یک جریان
- 4. مدت زمان جریان (duration time): تفاوت بین زمان پایان و زمان شروع
  - 5. تعداد بستهها در یک جریان (number of packets)
- 6. حجم بایتهای یک جریان (bytes of a flow): مجموع بایتهای بستهها در یک جریان

#### راهنمایی برای پیادهسازی:

#### برای خواندن پکتها از فایلهای

pcap، از کتابخانه scapy در پایتون استفاده کنید. تابع sniff در scapy امکان خواندن بستهها از یک فایل pcap، و ارسال اطلاعات هر بسته به یک تابع تعریفشده توسط کاربر را فراهم می کند.

#### تابع

create\_flow\_using\_sniff (یا نام مشابه) شما باید بسته ها را به عنوان ورودی بگیرد و جریان های مربوطه را تولید کند. مثال استفاده:

sniff(offline=pcap\_file, prn=create\_flow\_using\_sniff)

برای هر پکت، اطلاعات زیر را استخراج کنید : آدرس و پورت مبدأ، آدرس و پورت مقصد، حجم اطلاعات بدنه بسته، و زمان رسیدن بسته.

با استفاده از این اطلاعات، همه جریانهایی که تا به حال ساخته شدهاند را بررسی کنید. اگر شروط ذکر شده در مقاله (یکی بودن مبدا و مقصد یا یکی بودن مبدا پکت با مقصد جریان و بالعکس، و رسیدن پکت در بازه زمانی مشخص از آخرین پکت جریان) برای پکت مورد بررسی و جریان پیدا شده برقرار بود، این پکت را به جریان پیدا شده اضافه کنید. در غیر این صورت، با استفاده از این پکت یک جریان جدید بسازید.

#### • (درصد نمره اضافی - اختیاری) Filter

برای کاهش حجم و نویز در ردیابیهای شبکه، ترافیکی که احتمالاً به باتنتهای P2P مرتبط نیست، فیلتر می شود. این فیلتر برای رویکرد تشخیص حیاتی نیست، اما به کاهش ترافیک و افزایش کارایی تشخیص کمک می کند.

فیلتر در سه مرحله انجام می شود:

- فیلتر کردن جریانهای با حجم کوچک: جریانهای C&C باتنتها معمولاً از بستههای کوچک تشکیل شدهاند و حجم کل بایتهای آنها معمولاً کم است. در مقابل، بسیاری از جریانهای قانونی (مانند جریانهای چندرسانهای) ممکن است حجم زیادی داشته باشند.
- 2. فیلتر کردن جریانهای طولانی: یکی دیگر از ویژگیهای جریانهای C&C این است که مدت زمان آنها معمولاً کوتاه است. جریانهای طولانی (مانند جلسات SSH یا اتصالات دسکتاپ از راه دور که ممکن است ساعتها فعال بمانند) در شبکه رایج هستند و می توانند نویز ایجاد کنند. این جریانها نادیده گرفته می شوند.
- 3. فیلتر کردن جریانهایی که به ندرت اتفاق میافتند: باتهای P2P به طور مکرر به همتایان خود در لیستهای همتایانشان متصل میشوند. بنابراین، جریانهای بین باتها و همتایانشان به طور مکرر اتفاق میافتند. جریانهایی که بین دو میزبان به ندرت اتفاق میافتند، ممکن است به باتنتها مرتبط نباشند.
- نکته: از آنجایی که باتهای P2P معمولاً از پورتهای تصادفی برای ارتباط استفاده میکنند (مانند Nugache )، شماره پورت نادیده گرفته شده و فقط آدرسهای IP و پروتکل یک جریان

در نظر گرفته میشوند.

#### بخش دوم) Flow Dependency Extractor (بخش دوم

این مؤلفه وابستگیهای جریان را کشف می کند و میزبانهایی را که دارای وابستگی جریان هستند، به عنوان میزبانهای کاندید در نظر می گیرد. این ماژول ابتدا وابستگیهای جریان دو سطحی را کشف کرده و سپس بر اساس آنها، وابستگیهای جریان چند سطحی را پیدا می کند. جریانهای وابستگی با امتیاز بالاتر از S\_dep\_th به عنوان وابستگیهای جریان واقعی در نظر گرفته می شوند.

#### • محاسبه تعداد رخداد (۱۵ درصد نمره)

برای تشخیص وابستگی جریانها، لازم است قبل از شروع تشخیص، تعداد رخداد هر جریان را شمرده و آن را برای همه جریانها ذخیره کنید.

راهنمایی: تابعی بنویسید که همه جریانهای مورد نظر را بگیرد. برای هر جریان، اگر تعداد تکرارش قبلاً حساب شده باشد، آن را دوباره بررسی نکند. اما اگر تعداد تکرارش حساب نشده باشد، تعداد تکرار را حساب کرده و مقدار آن را برای همه جریانهای یکسان ذخیره کند.

#### ساخت وابستگی جریان دولایهای (۳۰ درصد نمره)

چگونه وابستگیهای جریان دو سطحی را در یک ردیابی معین استخراج کنیم؟ بینش کلیدی ما این است که اگر یک جفت جریان به طور مداوم با هم رخ دهند، ممکن است رابطه وابستگی داشته باشند. ما وابستگی جریانها را با جستجو برای همبستگی زمانی جریانها کشف می کنیم. به عنوان مثال، اگر جریان B بلافاصله پس از جریان A مشاهده شود، می توان فرض کرد که جریان B به جریان A وابسته است. در حالی که همبستگی زمانی ممکن است همیشه نشاندهنده ی یک وابستگی واقعی نباشد، برای کاهش موارد مثبت کاذب به تعداد زیادی نمونه تکیه می کنیم. به عبارت دیگر، ایده ما استخراج جفت جریانهایی است که به طور مکرر با هم رخ میدهند و به طور مداوم در طول زمان تکرار می شوند. با این حال، ممکن است تعداد زیادی جریان در چند ساعت وجود داشته باشد. بررسی هر جفت جریان پرهزینه، غیرقابل مقیاس بندی و ناکار آمد است. برای حل این مشکل، رویکرد ما دو اکتشافی را به کار می برد:

- 1. با توجه به یک جریان فعلی، فقط جریانهایی را تحلیل می کنیم که پس از یک زمان کوتاه از جریان فعلی شروع می شوند، زیرا یک جریان معمولاً به جریانی وابسته است که اخیراً رخ داده است.
  - 2. فقط جریانهایی را تحلیل می کنیم که تقریباً تعداد دفعات یکسانی رخ می دهند. اگر دو جریان همیشه با هم رخ دهند، تعداد رخدادهای این جریانها در یک دوره زمانی تقریباً با هم برابر خواهد

#### برای پیادهسازی این روش:

- مربوط به  $G_h$  مربوط به  $G_h$  در مجموعه  $G_h$  (جریانهای کاندید در یک دوره)، مجموعه جریانهای  $G_h$  مربوط به  $G_h$  آن میزبان را پیدا کنید.
  - $G_h$  بر اساس زمان شروعشان مرتب کنید.  $G_h$
  - میشوند.  $f_i$  برای هر جریان  $f_i$  در  $G_h$ ، جریانهای  $f_i$  را پیدا کنید که در بازه زمانی  $T_i$  پس از  $f_i$  شروع میشوند.
- کمتر از  $|N_j-N_i|$  ریعنی  $|N_j-N_i|$  کمتر از  $|N_j-N_i|$  کمتر از کم
- $f_i \leftarrow f_i$  به عنوان یک وابستگی جریان کاندید در اگر این شرط هم برای دو جریان مورد نظر برقرار بود، آنگاه  $f_i \leftarrow f_i$  به عنوان یک وابستگی جریان کاندید در نظر گرفته می شود. متغیر  $T_{ij}$  نشان دهنده تعداد دفعاتی است که  $f_i$  بلافاصله پس از  $f_i$  رخ می دهد و یک واحد به آن اضافه می شود.
  - ۰ برای محاسبه امتیاز وابستگی دو جریان از فرمول زیر استفاده کنید:

$$S_{dep}(f_i \rightarrow f_j) = \frac{Tij}{\sqrt{Ni \cdot Nj}}$$

که در آن  $N_i$  تعداد رخدادهای جریان  $f_i$  است. هر چه این امتیاز بیشتر باشد، احتمال وابستگی دو جریان بیشتر است. اگر امتیاز یک وابستگی جریان واقعی در نظر می گیریم.  $S_dep_t$  بزرگتر باشد، آن را به عنوان یک وابستگی جریان واقعی در نظر می گیریم. الگوریتم کامل پیاده سازی این قسمت طبق مقاله (Algorithm 1) به صورت زیر می باشد:

Algorithm 1 Extracting two-level flow dependencies
Input: F-the set of candidate flows during an epoch
Output: Two-level flow dependencies

Compute the number of occurrences
 for each flow f in F, denoted as N\_i

foreach local host h in F do
 Find the set of flows G\_h of h
 Sort the flows in G\_h in the order of start time
 foreach flow f\_i in G\_h do
 Find flows F\_h start after f\_i within T\_dep
 foreach flow f\_j in F\_h do
 if |N\_i - N\_j| < N\_dep then

 $\begin{tabular}{ll} if $f\_i$ -> $f\_j$ in candidate flow dependencies set D then \\ $T\_ij = T\_ij + 1$ \\ else \\ $Insert $f\_i$ -> $f\_j$ to D \\ for each $f\_i$ -> $f\_j$ in D do \\ $Compute $S\_dep(f\_i$ -> $f\_j($ \\ if $S\_dep(f\_i$ -> $f\_j) > $S\_dep\_th$ then \\ $Label $f\_i$ -> $f\_j$ as true flow dependency \\ \end{tabular}$ 

## • ساخت وابستگی جریان چند لایهای (۲۰ درصد نمره)

امتیاز یک وابستگی جریان k-سطحی به صورت زیر محاسبه می شود:

$$S(f1 \rightarrow f2 \rightarrow ... \rightarrow fk) = \left(\prod_{i=1}^{k-1} S(fi \rightarrow fi + 1)\right)$$

هنگام کشف وابستگیهای جریان چند سطحی، فقط وابستگیهای جریان واقعی را در نظر می گیریم که امتیاز آنها از S\_dep\_th بیشتر باشد. میزبانهای محلی که دارای وابستگیهای جریان دو سطحی یا چند سطحی هستند، به احتمال زیاد باتهای P2P هستند و به عنوان میزبانهای کاندید در نظر گرفته می شوند.

راهنمایی: برای تشخیص وابستگیهای چند لایهای، در ابتدا باید همه وابستگیهای دولایهای را با خودشان بررسی کنیم و به صورت بازگشتی یا تکراری وابستگیهای با سطوح بالاتر را بسازیم.

#### بخش سوم) Bots Detector ( درصد نمره - اضافی)

پس از کشف وابستگیهای جریان، ماژول Bots Detector برای شناسایی باتهای P2P اعمال میشود.

#### • محاسبه فاصله (۱۵ درصد نمره اضافی)

در مرحله اول، فاصله بین هر جفت از میزبانهای کاندید محاسبه می شود. همانطور که قبلاً ذکر شد، باتهای یک بات بات P2P با همتایان موجود در لیستهای خود برای دریافت دستورات یا بروزرسانی ها ارتباط برقرار می کنند. اگرچه باتهای مختلف به همتایان مختلفی در لیستهای خود متصل می شوند، اما احتمال دارد که هر جفت از باتهای P2P باتهای مختلف به همتای مشترک متصل شوند، زیرا باتهای یک بات نت از پروتکل P2P و شبکه یکسانی استفاده می کنند. بر اساس این مشاهده، فاصله بین میزبانهای کاندید با توجه به همپوشانی میزبانهای مشترک در وابستگیهای جریان آنها اندازه گیری می شود.

با داشتن مجموعهای از وابستگیهای جریان k-سطحی، از ضریب شباهت جاکارد برای اندازه گیری شباهت k-ام بین دو میزبان k استفاده می کنیم. شباهت k-ام به صورت زیر تعریف می شود:

$$\mathit{Sim}^{(k)}(H_{a}, H_{b}) = \begin{cases} \frac{\left| \mathit{DEP}_{a}^{(k)} \cap \mathit{DEP}_{b}^{(k)} \right|}{\left| \mathit{DEP}_{a}^{(k)} \cup \mathit{DEP}_{b}^{(k)} \right|} & \textit{if} \left| \mathit{DEP}_{a}^{(k)} \cap \mathit{DEP}_{b}^{(k)} \right| \neq 0, \left| \mathit{DEP}_{a}^{(k)} \cup \mathit{DEP}_{b}^{(k)} \right| \neq 0 \\ 0 & \textit{otherwise} \end{cases}$$

که در آن  $P_a^{(k)} = DEP_b^{(k)}$  به ترتیب مجموعههای میزبانهای راه دور در وابستگیهای جریان  $P_b^{(k)} = DEP_b^{(k)}$  که در آن  $P_a^{(k)} = P_a^{(k)}$  به ترتیب مجموعههای میزبان  $P_a$ 

سپس فاصله بین دو میزبان  $H_a$  و  $H_b$  به صورت زیر تعریف می شود:

$$Dist(H_a, H_b) = \sum_{k=2}^{n} w_k * \left(1 - Sim^{(k)}(H_a, H_b)\right), w_k$$
$$= \frac{k}{\sum_{k=2}^{n} k}$$

 $w_k$  وزن k-ام فاصله است و با تغییر  $w_k$  نیز تغییر می کند. همانطور که قبلاً دیدیم، میزبانهای عادی ممکن است و  $w_k$  با  $w_k$  ،  $w_$ 

## راهنمایی:

- برای محاسبه فرمولهای فوق، نیاز دارید که برای هر میزبان (IP میزبان) و لیستی از وابستگیهای میزبان را داشته باشید؛ به این صورت که هر عضو از لیست دارای دو مقدار باشد: عدد لایه وابستگی و تمام مقصدهایی که در این وابستگی بودهاند. پس نیاز به تابعی دارید که بتواند این اطلاعات را به دست آورد.
  - سپس طبق فرمول ارائه شده در مقاله فاصله را محاسبه کنید.
    - o در نهایت یک ماتریس فاصله (Distance Matrix )

می شود، که ab = ab \* ab = dist(Ha, Hb) شامل فاصله ab = dist(Ha, Hb) بین هر جفت از میزبان ها ساخته می شود، که ab = ab \* ab = ab تعداد میزبان های کاندید است.

## • خوشهبندی میزبانها (۱۰ درصد نمره - اضافی)

پس از محاسبه فاصله، یک الگوریتم خوشهبندی سلسلهمراتبی تک-پیوندی ( Single-linkage hierarchical clustering پس از محاسبه فاصله، یک الگوریتم که اعمال می شود. این الگوریتم D را به عنوان ورودی می گیرد و یک دندرو گرام (algorithm بر روی ماتریس فاصله D اعمال می شود. این الگوریتم D را به عنوان ورودی می گیرد و یک دندرو گرام، برگها (dendrogram) تولید می کند که یک گراف شبیه درخت است (شکل 7 مقاله را ببینید). در این دندرو گرام، برگها نشان دهنده میزبانهای اصلی و طول یالها نشان دهنده فواصل بین خوشهها هستند.

دندروگرام رابطه بین میزبانها را نشان میدهد. هر چه فاصله بین دو میزبان کمتر باشد، یال اتصال آنها در دندروگرام کوتاهتر است. برای گروهبندی میزبانها به خوشهها، پارامتری به نام dist\_th برای برش دندروگرام در ارتفاع مشخصی استفاده میشود.

dist\_th بر اساس توزیع فواصل میان میزبانها تنظیم می شود. اگر برخی میزبانها فواصل کمی با یکدیگر داشته باشند و یک خوشه متراکم تشکیل دهند و میزبانهای دیگر فواصل بزرگ تری داشته باشند، dist\_th در میانه فواصل کوچک و بزرگ تنظیم می شود.

dist\_th بسیار بزرگ ممکن است منجر به موارد مثبت کاذب شود (میزبانهای عادی به خوشههای باتنت خوشهبندی شوند)، در حالی که dist\_th بسیار کوچک ممکن است منجر به موارد منفی کاذب شود (برخی باتها تشخیص داده نشوند). بنابراین، dist\_th باید بر اساس توزیع فواصل تنظیم شود. خوشههایی که زیر dist\_th قرار می گیرند به عنوان خوشههای بات طبقهبندی می شوند.

#### 4. گزارش (۱۰ درصد نمره)

یک گزارش جامع از روند کار، شامل توضیحات پیادهسازی هر بخش، چالشهای پیش رو و راهحلهای اتخاذ شده، به همراه فایل کدها ارائه دهید. حتی در صورت عدم موفقیت در پیادهسازی کامل، ارائه گزارشی شامل الگوریتمهای مقاله و روش کارتان، نمره مربوطه را به دنبال خواهد داشت.

نکته: برای ارزیابی عملکرد پیادهسازی خود، می توانید از معیارهای Detection Rate (DR) و False Positive Rate (FPR) که در مقاله (بند 4.2، صفحه 327) تعریف شدهاند، استفاده کنید.

#### نکات مهم و راهنماییها برای دانشجویان:

- زبان برنامهنویسی: پیشنهاد می شود که از زبان برنامهنویسی پایتون استفاده کنید ، زیرا این زبان کتابخانههای بسیار مفیدی (مانند scapy برای خواندن اطلاعات شبکه ) برای پیادهسازی ساده تر در اختیار شما قرار می دهد.
- دیتاست: برای دیتاست، فایلهای pcap به صورت آماده در اینترنت هستند و میتوانید از آنها استفاده کنید. این فایلها شامل پکتهای مشاهده شده بر روی یک شبکه هستند. (یک نمونه از pcap. در فایل قرار داده شده است.)
  - منابع: مقاله اصلی را با دقت مطالعه کنید؛ جزئیات پیادهسازی به طور کامل در آن ذکر شده است.
  - زمان تحویل پروژه : ساعت ۱۱:۵۹ شب ۲۸ مرداد ماه ۱۴۰۴ زمان تحویبل آنلاین متعاقبا اعلام خواهد شد.
    - ارزیابی: در موقع تحویل آنلاین، تسلط کامل بر پروژه ملاک عمل است و صرفاً بارگذاری پروژه کافی نیست.
    - ارتباط: سوالات خود را مي توانيد به آدرس ايميل fatemeh.abbasi4@webmail.sbu.ac.ir ارسال كنيد.

#### معیارهای ارزیابی عملکرد

عملکرد رویکرد با Detection Rate (DR) و False Positive Rate (FPR) اندازه گیری می شود.

• Detection Rate (DR): نرخ باتهایی است که به درستی شناسایی شدهاند. با فرمول زیر تعریف میشود:

#### DR = TP + FNTP

TP تعداد موارد مثبت واقعی (باتهایی که به عنوان بات طبقهبندی شدهاند) و FN تعداد موارد منفی کاذب (باتهایی که به عنوان غیربات طبقهبندی شدهاند) است.

• (False Positive Rate (FPR: نرخ میزبانهای عادی است که به اشتباه به عنوان بات طبقهبندی شدهاند. با فرمول زیر تعریف می شود:

#### FPR = FP + TNFP

FP تعداد موارد مثبت کاذب (غیرباتهایی که به عنوان بات طبقهبندی شدهاند) و TN تعداد موارد منفی واقعی (غیرباتهایی که به عنوان غیربات طبقهبندی شدهاند) است.

#### بحث و تحلیل (جهت راهنمایی دانشجو برای بخش گزارش)

روش پیشنهادی باتنتهای P2P را با کشف وابستگیهای جریان شناسایی می کند. جریانهای وابسته باید به طور مکرر با هم اتفاق بیفتند. اگر این جریانها به ندرت اتفاق بیفتند، روش ممکن است در کشف وابستگی جریان دچار مشکل شود. این محدودیت در تکنیکهای کشف وابستگی مبتنی بر شبکه رایج است. این محدودیت را می توان با افزایش دوره زمانی دادههای جمع آوری شده کاهش داد.

میزبانهای P2P قانونی نیز ممکن است به طور مکرر به همتایان خود در لیستهای همتایانشان متصل شوند تا فایلها را جستجو کنند یا شبکه P2P را حفظ کنند. آنها نیز ممکن است وابستگی جریان داشته باشند. در این روش، دو راه برای طبقهبندی میزبانهای P2P قانونی و باتهای P2P وجود دارد:

- 1. بر اساس زمان فعالیت: زمان فعالیت میزبانهای P2P قانونی ممکن است کوتاه باشد و معمولاً توسط کاربران تعیین میشود. مثلاً کاربران ممکن است پس از دانلود فایلها، برنامه P2P را ببندند. در حالی که زمان فعالیت باتهای P2P طولانی است، زیرا تا زمانی که سیستم زیرین فعال باشد، اجرا میشوند. بنابراین، تعداد نمونههای وابستگی جریان میزبانهای P2P قانونی ممکن است کمتر از باتهای P2P باشد و مقدار  $T_{ij}$  جریانهای قانونی ممکن است کمتر از باتهای P2P باشد و مقدار باشد.
- 2. بر اساس خوشهبندی: فرآیند خوشهبندی می تواند میزبانهای P2P قانونی را حذف کند. از آنجایی که میزبانهای P2P قانونی مختلف تمایل دارند فایلهای مختلفی را جستجو کنند و همتایانی که به آنها متصل می شوند احتمال همپوشانی کمی دارند، فاصله میزبانهای P2P قانونی بزرگ است و آنها نمی توانند یک خوشه متراکم تشکیل دهند. از سوی دیگر، باتهای P2P در یک باتنت معمولاً به همتایان مشترک متصل می شوند و فواصل آنها کوچک است، بنابراین می توانند یک خوشه متراکم تشکیل داده و شناسایی شوند.